



SISTEMAS DE INFORMAÇÃO

Projeto Final — Aprendizagem de Máquina

Classificação de Doenças Respiratórias a Partir de Sintomas Utilizando Técnicas de Aprendizagem de Máquina

Alunos:

Caio Moura Portela Sousa — Matrícula: 2313080152

João Matheus de Figueiredo Tavares — Matrícula: 2313080092

Prof. Bruno Rafael Araújo Vasconcelos
bruno.vasconcelos@maisunifacisa.com.br

Classificação de Doenças Respiratórias a Partir de Sintomas Utilizando Técnicas de Aprendizagem de Máquina

Caio Moura Portela Sousa¹, João Matheus de Figueiredo Tavares¹

¹Sistemas de Informação — UNIFACISA Centro Universitário

Prof. Bruno Rafael Araújo Vasconcelos — Aprendizagem de Máquina

Abstract.

This work presents the development and evaluation of machine learning models for classifying three respiratory diseases — Pneumonia, Acute Bronchitis, and Asthma — based on binary symptom data from the Kaggle "Diseases and Symptoms" dataset (246,945 records, 773 diseases). Four algorithms were compared: Decision Tree, Random Forest, Logistic Regression, and Neural Network (MLP). Feature selection techniques (Chi-squared and Mutual Information) reduced the input from 377 to 17 relevant symptoms. All models achieved approximately 90% accuracy, with Decision Tree and Neural Network obtaining the best test accuracy (89.7%).

Resumo.

Este trabalho apresenta o desenvolvimento e a avaliação de modelos de aprendizagem de máquina para a classificação de três doenças respiratórias — Pneumonia, Bronquite Aguda e Asma — a partir de sintomas binários do dataset "Diseases and Symptoms" do Kaggle (246.945 registros, 773 doenças). Foram comparados quatro algoritmos: Árvore de Decisão, Random Forest, Regressão Logística e Rede Neural (MLP). Técnicas de seleção de features (Chi-quadrado e Informação Mútua) reduziram a entrada de 377 para 17 sintomas relevantes. Todos os modelos alcançaram acurácia próxima de 90%, com a Árvore de Decisão e a Rede Neural obtendo a melhor acurácia no teste (89,7%).

1. Introdução

O diagnóstico médico é uma das tarefas mais complexas na área da saúde. Muitas são as variáveis para se concluir que determinado paciente está com determinada doença. Às vezes, um sintoma pode estar presente e indicar fortemente uma condição, enquanto outro sintoma também presente pode apontar para um diagnóstico totalmente diferente. O diagnóstico errado pode trazer sérias consequências para o paciente.

Doenças respiratórias como Pneumonia, Bronquite Aguda e Asma representam um desafio particular, pois compartilham diversos sintomas em comum — tosse, falta de ar, febre, dor no peito e congestão torácica. Essa sobreposição de sintomas dificulta o diagnóstico diferencial e pode levar a tratamentos inadequados. Neste contexto, técnicas de aprendizagem de máquina surgem como ferramentas promissoras para auxiliar na tomada de decisão clínica, identificando padrões sutis nos dados que podem não ser evidentes para o profissional de saúde.

Este trabalho tem como objetivo desenvolver e avaliar modelos de classificação capazes de prever qual das três doenças respiratórias um paciente apresenta, a partir de um conjunto de sintomas codificados como variáveis binárias. O dataset utilizado é o "Diseases and Symptoms Dataset", disponível no Kaggle [Dhivyesh 2023], contendo 246.945 registros de pacientes com 773 tipos de doenças e 377 sintomas. Para este estudo, foram selecionadas Pneumonia (1.212 amostras), Bronquite Aguda (1.213 amostras) e Asma (904 amostras), totalizando 3.329 registros.

Todo o desenvolvimento foi realizado em Jupyter Notebook [Jupyter 2023], conforme requerido pelo projeto, utilizando as bibliotecas Scikit-learn [Pedregosa et al. 2011], Pandas [McKinney 2010],

Matplotlib [Hunter 2007] e Seaborn. Foram implementados e comparados quatro modelos: Árvore de Decisão, Random Forest [Breiman 2001], Regressão Logística e Rede Neural Artificial (MLP). Além da avaliação dos modelos, foram aplicadas técnicas de seleção de features para identificar os sintomas mais relevantes para a classificação, buscando reduzir a dimensionalidade e melhorar a interpretabilidade.

2. Metodologia

2.1. Descrição do Dataset

O dataset original do Kaggle contém 246.945 amostras com 378 colunas: uma coluna identificando a doença e 377 colunas de sintomas binários (presença ou ausência). Após a filtragem para as três doenças escolhidas, o dataset resultante contém 3.329 amostras. Das 377 colunas de sintomas, apenas 17 apresentaram variância maior que zero, indicando que a grande maioria dos sintomas não é relevante para estas condições específicas. As 360 colunas restantes foram removidas por conterem exclusivamente valores zero.

2.2. Ambiente de Desenvolvimento

Todo o trabalho foi implementado utilizando o Jupyter Notebook, ambiente que permite combinar código executável em Python, visualizações gráficas e texto explicativo em um único documento interativo, facilitando a reprodutibilidade dos experimentos. As principais bibliotecas utilizadas foram: Pandas para manipulação e exploração dos dados, Scikit-learn para os modelos de aprendizagem de máquina e seleção de features, Matplotlib e Seaborn para as visualizações gráficas, e NumPy para operações numéricas. O notebook completo com todo o código-fonte e resultados executados acompanha este artigo.

2.3. Análise Exploratória dos Dados

A análise exploratória incluiu a verificação da distribuição das classes, a análise da frequência de cada sintoma por doença, o cálculo de correlações entre sintomas e a distribuição do número total de sintomas por paciente. O dataset apresenta um leve desbalanceamento, com Asma tendo menos amostras (904) que Pneumonia (1.212) e Bronquite Aguda (1.213).




Figura 1. Distribuição das classes no dataset filtrado do Kaggle.




Figura 2. Frequência dos sintomas mais discriminativos por doença.

A Figura 2 revela padrões importantes: a Asma se distingue pela alta prevalência de reação alérgica e aperto no peito; a Pneumonia se destaca por vômito, dor de cabeça, fraqueza e calafrios; e a Bronquite Aguda é caracterizada pela expectoração e dor de garganta. Esses padrões, embora distintos, apresentam sobreposição significativa, tornando a classificação desafiadora.




Figura 3. Mapa de calor — correlação entre os sintomas relevantes.




Figura 4. Distribuição do número total de sintomas por doença.

A Figura 4 mostra que pacientes com Pneumonia tendem a apresentar mais sintomas simultaneamente do que pacientes com Asma ou Bronquite Aguda, refletindo o caráter mais sistêmico da infecção pneumônica.

2.4. Seleção de Features

A seleção de features é uma etapa fundamental para reduzir o overfitting, diminuir o tempo de treinamento e melhorar a interpretabilidade dos modelos [Hastie et al. 2009]. Foram aplicadas duas técnicas complementares: o teste Chi-quadrado, que avalia a dependência estatística entre cada feature e a variável-alvo, e a Informação Mútua, que mede a quantidade de informação compartilhada entre as variáveis. Ambas são adequadas para dados binários.




Figura 5. Seleção de features: Chi-quadrado (esquerda) e Informação Mútua (direita).

As duas técnicas apresentaram concordância nos nove sintomas mais importantes: reação alérgica, aperto no peito, vômito, dor de cabeça, fraqueza, congestão torácica, calafrios, expectoração e dor de garganta. Abaixo destes, os scores caem drasticamente, indicando que os demais sintomas (tosse, falta de ar, coriza) não contribuem significativamente para a diferenciação entre as três doenças.




Figura 6. Impacto do número de features na acurácia do modelo.

A Figura 6 confirma que a acurácia estabiliza com aproximadamente nove features, demonstrando que os sintomas adicionais não agregam poder discriminativo. Sintomas genéricos como tosse e falta de ar, embora comuns em doenças respiratórias, não ajudam a diferenciar entre as três condições estudadas.

2.5. Modelos Implementados

Foram implementados quatro modelos de classificação, cujos hiperparâmetros são apresentados na Tabela 1. Os dados foram divididos em 70% para treinamento (2.330 amostras) e 30% para teste (999 amostras), utilizando estratificação para manter a proporção das classes. Além disso, foi aplicada validação cruzada estratificada com cinco folds para avaliar a capacidade de generalização.

Tabela 1. Modelos implementados e seus hiperparâmetros.

Modelo	Hiperparâmetros Principais
Árvore de Decisão	max_depth=10, min_samples_leaf=5
Random Forest	n_estimators=100, max_depth=15
Regressão Logística	max_iter=1000, C=1.0, solver=lbfgs
Rede Neural (MLP)	hidden_layers=(128, 64), early_stopping=True

2.6. Métricas de Avaliação

Para avaliar os modelos, foram utilizadas as seguintes métricas: Matriz de Confusão, que permite visualizar os acertos e erros para cada classe; Acurácia, a proporção total de classificações corretas; Precisão, a proporção de verdadeiros positivos dentre as predições positivas; Recall, a proporção de verdadeiros positivos identificados; F1-Score, a média harmônica entre Precisão e Recall; e Validação Cruzada estratificada com cinco folds, que avalia a robustez e a capacidade de generalização dos modelos.

3. Resultados e Discussão

3.1. Matrizes de Confusão

As matrizes de confusão dos quatro modelos são apresentadas na Figura 7. O principal desafio observado é a confusão entre Pneumonia e Bronquite Aguda, que compartilham sintomas respiratórios semelhantes. A Asma, por sua vez, é classificada com maior precisão graças aos sintomas alérgicos distintos.




Figura 7. Matrizes de confusão dos quatro modelos avaliados.

3.2. Comparação de Métricas

Tabela 2. Resultados consolidados dos modelos avaliados.

Modelo	Acurácia	Precisão	Recall	F1-Score	CV (5-fold)
Árvore de Decisão	89,7%	89,7%	89,7%	89,7%	90,3% ± 0,7%
Random Forest	88,9%	88,9%	88,9%	88,9%	88,8% ± 0,8%
Regressão Logística	89,6%	89,9%	89,6%	89,6%	90,3% ± 0,7%
Rede Neural (MLP)	89,7%	90,1%	89,7%	89,6%	90,3% ± 0,8%

Todos os modelos apresentaram desempenho semelhante, com acurácias entre 88,9% e 89,7%. Essa convergência sugere que o limite de desempenho está mais relacionado à natureza dos dados e à sobreposição de sintomas do que à capacidade dos algoritmos. A Árvore de Decisão e a Rede Neural empataram na melhor acurácia (89,7%), enquanto a Regressão Logística apresentou a melhor precisão ponderada (89,9%). Na validação cruzada, três dos quatro modelos alcançaram 90,3%, demonstrando boa capacidade de generalização.

O Random Forest, surpreendentemente, obteve o pior resultado (88,9%). Isso pode ser explicado pelo número reduzido de features (17): o mecanismo de amostragem aleatória de features do Random Forest pode ser contraproducente quando há poucas variáveis, pois cada árvore individual pode perder acesso aos sintomas mais discriminativos.




Figura 8. Comparação visual das métricas entre os modelos.

3.3. Validação Cruzada




Figura 9. Boxplot da validação cruzada (5-fold) para os quatro modelos.

A validação cruzada confirma a estabilidade dos modelos, com desvio padrão inferior a 1% em todos os casos. A Regressão Logística e a Árvore de Decisão apresentaram os resultados mais consistentes entre os folds.

3.4. Interpretabilidade




Figura 10. Visualização dos primeiros três níveis da Árvore de Decisão.

A visualização da Árvore de Decisão (Figura 10) revela que o primeiro split utiliza o sintoma "allergic reaction" (reação alérgica), separando a Asma das demais condições. Em seguida, sintomas como "coughing up sputum" (expectoração) e "headache" (dor de cabeça) diferenciam Pneumonia de Bronquite Aguda. Essa sequência é clinicamente coerente.




Figura 11. Importância das features segundo o Random Forest.

3.5. Métricas por Classe




Figura 12. Precisão, Recall e F1-Score por classe para o melhor modelo.

A análise por classe (Figura 12) mostra que a Asma é a doença mais fácil de classificar (F1-Score de 0,91), graças aos sintomas alérgicos distintos. A confusão entre Pneumonia e Bronquite Aguda é o principal fator limitante do desempenho global dos modelos.

4. Conclusão e Trabalhos Futuros

Este trabalho demonstrou a viabilidade de modelos de aprendizagem de máquina na classificação de doenças respiratórias a partir de sintomas, utilizando dados reais do Kaggle. Os quatro modelos avaliados — Árvore de Decisão, Random Forest, Regressão Logística e Rede Neural — alcançaram acurácias próximas de 90%, demonstrando que é possível diferenciar Pneumonia, Bronquite Aguda e Asma com base em sintomas.

A análise de seleção de features revelou que dos 377 sintomas originais do dataset, apenas 17 são relevantes para as três doenças e, destes, nove são verdadeiramente discriminativos. Os mais importantes são: reação alérgica (diferencia Asma), expectoração (diferencia Bronquite) e sintomas sistêmicos como vômito, dor de cabeça e calafrios (diferenciam Pneumonia).

A similaridade nos resultados dos quatro modelos sugere que o limitante de desempenho é a natureza dos dados, não a capacidade dos algoritmos. Para aplicação prática, recomenda-se a Árvore de Decisão pela interpretabilidade ou a Regressão Logística pela estabilidade na validação cruzada.

Como trabalhos futuros, sugere-se a incorporação de variáveis numéricas (como temperatura corporal e frequência cardíaca), a aplicação de técnicas de otimização de hiperparâmetros (Grid Search ou Random Search), a expansão para um conjunto maior de doenças e a validação com dados clínicos reais em ambiente hospitalar.

Referências

- Breiman, L. (2001). Random Forests. *Machine Learning*, v. 45, n. 1, p. 5-32.
- Dhiviyesh, R. K. (2023). Diseases and Symptoms Dataset. Kaggle. Disponível em: <https://www.kaggle.com/datasets/dhiviyeshrk/diseases-and-symptoms-dataset>.
- Hastie, T., Tibshirani, R. e Friedman, J. (2009). *The Elements of Statistical Learning*. 2. ed. Springer.
- Hunter, J. D. (2007). Matplotlib: A 2D graphics environment. *Computing in Science & Engineering*, v. 9, n. 3, p. 90-95.
- Jupyter Project (2023). Jupyter Notebook. Disponível em: <https://jupyter.org/>.
- McKinney, W. (2010). Data Structures for Statistical Computing in Python. *Proceedings of the 9th Python in Science Conference*, p. 51-56.

Pedregosa, F. et al. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, v. 12, p. 2825-2830.